

**PRACTICA No. 1**

**Noticias Falsas**

**Profesor:** Jaime Alberto Guzmán Luna

**Valor:** 20 % de la nota del curso

**Fecha de entrega:** miércoles 7 de octubre hasta las 12 del medio día

**Fecha de Sustentación:** miércoles 7 de octubre de 4 a 8 pm.

**CONCEPTOS BÁSICOS**

**REQUISITOS GENERALES**

- El trabajo se realizará por el equipo acorde al listado definido en clase.
- Se realizará una exposición en la fecha correspondiente de entrega durante clase. El tiempo de la exposición son 15 minutos y 5 para preguntas

**OBJETIVOS DE LA PRACTICA**

- Objetivo General: Desarrollar una aplicación de Procesamiento del Lenguaje Natural (PLN) que permita analizar y clasificar noticias en español como verdaderas o falsas sobre un tema específico (p. ej., salud, política, tecnología), mediante la construcción de un corpus (propio + corpus curado), la aplicación de técnicas de preprocesamiento y representación textual, el análisis lingüístico y semántico mediante POS Tagging, Reconocimiento de Entidades Nombradas (NER) y Modelado de Temas (Topic Modeling), y la implementación y evaluación comparativa de diferentes algoritmos de aprendizaje automático y sus conclusiones.
- Objetivos Específicos:
  - Construir un corpus de noticias en español a partir de dos fuentes: documentos obtenidos directamente desde la Web mediante técnicas de web scraping y un corpus existente previamente curado, manteniendo un conjunto balanceado entre noticias verdaderas y falsas.
  - Aplicar técnicas de preprocesamiento, limpieza y normalización textual que permitan reducir el ruido presente en los documentos y preparar adecuadamente el corpus para las posteriores tareas de PLN y aprendizaje automático.
  - Representar los documentos mediante técnicas de extracción y ponderación de características, considerando unigramas y bigramas mediante el modelo Bag of Words (BoW), eliminación de stopwords, reducción por frecuencia, stemming, frecuencia absoluta (TO) y TF-IDF, de acuerdo con las técnicas establecidas en las respectivas secciones de la práctica
  - Aplicar técnicas de Etiquetado de Partes de la Oración (POS Tagging) para identificar las categorías gramaticales presentes en las noticias y analizar comparativamente su distribución entre noticias verdaderas y falsas, considerando categorías como

sustantivos (NOUN), verbos (VERB), adjetivos (ADJ), adverbios (ADV) y pronombres (PRON).

- Aplicar técnicas de Reconocimiento de Entidades Nombradas (NER) para identificar y clasificar las principales entidades mencionadas en las noticias, tales como personas, organizaciones y localizaciones, y analizar posibles diferencias en su presencia y frecuencia entre noticias verdaderas y falsas.
- Aplicar técnicas de Modelado de Temas (Topic Modeling) para descubrir automáticamente los principales temas subyacentes presentes en el corpus de noticias, utilizando los métodos Latent Semantic Analysis (LSA) y Latent Dirichlet Allocation (LDA) vistos en clase.
- Determinar y justificar un número apropiado de temas para el modelado, utilizando métricas como el Score de Coherencia, e interpretar los temas obtenidos a partir de sus términos más representativos.
- Comparar la distribución de los temas identificados entre noticias verdaderas y falsas, con el propósito de establecer si existen diferencias temáticas relevantes entre ambas categorías.
- Entrenar y comparar diferentes algoritmos de aprendizaje automático supervisado —Regresión Logística, Árboles de Decisión, KNN y SVM— para clasificar las noticias como verdaderas o falsas, considerando las diferentes configuraciones de preprocesamiento y ponderación establecidas en el contenido específico de la práctica.
- Evaluar comparativamente los modelos de clasificación mediante las métricas Accuracy, Precision, Recall y F1-score, utilizando validación cruzada y tomando el F1-score ponderado como medida de referencia, de acuerdo con el esquema experimental definido en la práctica.
- Analizar conjuntamente los resultados obtenidos mediante POS Tagging, NER y Topic Modeling, con el propósito de identificar patrones lingüísticos, entidades y características temáticas que permitan caracterizar y diferenciar las noticias verdaderas de las falsas.
- Elaborar conclusiones integrales del estudio, relacionando los resultados del análisis lingüístico y semántico con el desempeño de los algoritmos de clasificación.

## 1. CREACION CORPUS

Fuente 1: Obtener un corpus de documentos .txt en español desde la web utilizando técnicas de web scraping (mínimo 50 .txt por cada miembro del equipo) haciendo uso de una de las dos herramientas vistas en clase (BeautifulSoup ó Selenium) y etiquetarlos mediante 2 carpetas acorde a su etiqueta de veracidad: carpeta Verdad (para verdaderos) y carpeta Falso (para los falsos). Este corpus estará balanceado con un número similar de textos para cada una de las carpetas. Este corpus será utilizado para el entrenamiento de las técnicas de aprendizaje planteadas.

Fuente 2: usar un corpus en español existente. Igual que la fuente anterior este corpus manejará dos categorías de noticias: Falsas y Verdaderas. Para nuestro

caso del corpus encontrado deberá usar mínimo 5000 (cinco mil) muestras tomadas de manera aleatoria que contenga noticias falsas (F) y noticias verdaderas (V). Esta muestra aleatoria debe ser de tal forma que el número de ambas categorías queden balanceadas y luego generar los txt como documentos que serán adicionados a sus respectivas carpetas /Verdad y /Falso. A estas 2 carpetas se sumarán los txt provenientes de la Fuente 1 obtenidos por web scraping. Estas 2 carpetas que contiene ambas fuentes conformarán el corpus definitivo (aprox. 5200 muestras si son 3 integrantes del equipo).

Una vez conformado este corpus, se realizará el cálculo de las siguientes métricas:

- Mean: La media es el promedio de palabras totales en cada archivo que compone una fuente
- Std: La Desviación Estándar mide la dispersión de las longitudes respecto a la media de palabras en cada archivo de la fuente
- Min: cantidad mínima de palabras entre las diferentes fuentes
- Max: cantidad máxima de palabras entre las diferentes fuentes
- Quartiles: Cuartiles (25%, 50% y 75%) de la cantidad de palabras entre las diferentes fuentes
- Sum: Total de palabras de las diferentes fuentes

## 2. PREPROCESAMIENTO

En esta fase se buscará limpiar y normalizar la información del corpus para evitar que determinados datos influyan de manera negativa en el resultado final. Para tal fin se realizarán las siguientes actividades:

- Normalización de mayúsculas y minúsculas: Todos los textos serán convertidos a su equivalente en letras minúsculas.
- Eliminación de tildes: En muchas fuentes de la Web es posible encontrar usuarios que no hacen buen uso de las tildes. Por lo tanto, útil y util (sin tilde en la letra u) pueden ser consideradas por las técnicas como palabras diferentes. Por lo tanto, se eliminarán todas las tildes de las vocales de los documentos de entrenamiento.
- Eliminación de números: en general, las cifras numéricas no tienen información que ayuden a determinar la veracidad de dichas noticias por lo cual se solicita removerlas de los textos.
- Enlaces: En muchos textos procedentes de la Web pueden existir enlaces a otras páginas Web (eje. [www.unal.edu.co](http://www.unal.edu.co)). Estos enlaces no aportan en general a determinar su veracidad de los documentos en los que están incluidos. Por esto se deberán eliminar.
- Eliminación de retornos de carro: algunos documentos contienen saltos de línea y retornos de carro, por lo que el texto aparece escrito en diferentes líneas. Estos elementos se deben eliminar para que los documentos aparezcan como una sola línea.
- Elementos HTML: Se deberán quitar todos los símbolos asociados al lenguaje HTML.
- Signos de puntuación y emoticones: Se eliminarán los signos de puntuación y emoticones.

## 3. ANÁLISIS LINGÜÍSTICO MEDIANTE POS TAGGING

A partir del corpus conformado en el numeral 1 se realizará un análisis de las categorías gramaticales presentes en las noticias mediante POS Tagging.

Para esta actividad se utilizará spaCy y un modelo disponible para español. Se deberán procesar independientemente las noticias pertenecientes a las categorías Verdad y Falso e identificar las etiquetas POS de sus tokens. Como mínimo se analizarán las siguientes categorías:

- Sustantivos (NOUN)
- Verbos (VERB)
- Adjetivos (ADJ)
- Adverbios (ADV)
- Pronombres (PRON)

Para cada categoría de noticias (Verdad/Falso) se deberá calcular la frecuencia absoluta y relativa de las anteriores categorías gramaticales.

Se deberá generar una tabla comparativa con la siguiente estructura:

| POS  | Verdaderas<br>(cantidad) | Verdaderas<br>(%) | Falsas<br>(cantidad) | Falsas<br>(%) |
|------|--------------------------|-------------------|----------------------|---------------|
| NOUN |                          |                   |                      |               |
| VERB |                          |                   |                      |               |
| ADJ  |                          |                   |                      |               |
| ADV  |                          |                   |                      |               |
| PRON |                          |                   |                      |               |

Igualmente se deberá:

- Generar un gráfico de barras comparativo que permita visualizar las diferencias entre las distribuciones POS de noticias verdaderas y falsas.
- Seleccionar adicionalmente los 10 sustantivos, 10 verbos y 10 adjetivos más frecuentes para cada categoría de noticias.
- Finalmente, realizar un análisis que responda: ¿Existen diferencias relevantes en el uso de categorías gramaticales entre noticias falsas y verdaderas?

#### 4. RECONOCIMIENTO DE ENTIDADES NOMBRADAS (NER)

Se aplicará Reconocimiento de Entidades Nombradas (NER) al corpus de noticias con el objetivo de identificar las principales entidades mencionadas y estudiar si existen diferencias entre las noticias verdaderas y falsas.

Para esta actividad se utilizará spaCy con un modelo disponible para español. Para cada documento se deberán extraer las entidades reconocidas por el modelo, almacenando como mínimo:

- Texto de la entidad.
- Tipo de entidad.
- Documento al cual pertenece.
- Etiqueta del documento: Verdad/Falso.

Los resultados deberán almacenarse en una estructura tabular. Por ejemplo:

| Documento  | Entidad              | Tipo | Clase  |
|------------|----------------------|------|--------|
| noticia001 | Universidad Nacional | ORG  | Verdad |
| noticia002 | Medellín             | LOC  | FALSO  |
| noticia003 | Juan Pérez           | PER  | FALSO  |

A partir de las entidades identificadas se deberán obtener:

- Número total de entidades identificadas en noticias verdaderas y falsas.
- Distribución porcentual de entidades por categoría.
- Las 10 entidades más frecuentes por tipo para noticias verdaderas y falsas.
- Las 20 entidades más frecuentes globalmente en cada categoría de noticias.

Generar al menos:

- Un gráfico comparativo de distribución de tipos de entidades entre noticias verdaderas y falsas.
- Un gráfico con las entidades más frecuentes en noticias verdaderas.
- Un gráfico con las entidades más frecuentes en noticias falsas.

Adicionalmente, realizar un análisis que responda: ¿Las noticias falsas y verdaderas presentan diferencias en los tipos o entidades específicas que mencionan?

Discutir si determinadas personas, organizaciones, lugares u otros tipos de entidades aparecen con mayor frecuencia en alguna de las dos categorías.

Por último, incluir en el informe una discusión breve sobre posibles errores observados en el reconocimiento de entidades, seleccionando al menos 5 ejemplos en los cuales el sistema haya identificado incorrectamente una entidad, haya asignado una categoría incorrecta o no haya reconocido una entidad que debería haber sido detectada.

## 5. EXTRACCIÓN DE CARACTERÍSTICAS

A partir del corpus obtenido en el paso anterior, se procederá a crear las características, haciendo uso del modelo de bolsa de palabras (bag of words-BoW). Para esto se realizará inicialmente el proceso de tokenización. Esta bolsa de palabras en nuestro caso contendrá *unigramas*, es decir tokens independientes, y *bigramas* formados por la concatenación de dos tokens preservando el orden original que estos tenían dentro del texto del que proceden.

Luego se llevará a cabo las tareas de reducción de stopwords. Para ello se realizarán dos tipos de procesos de stopwords:

- Eliminar los tokens (unigramas y bigramas) asociados a la lista de palabras de palabras vacías (stopword) predefinidas por las librerías vistas en clase para español se eliminan de la bolsa de palabras. En este grupo se incluyen pronombres, artículos, conjunciones, preposiciones, etc.
- Eliminar los tokens (unigramas y bigramas) mediante la eliminación por

frecuencia. Para este caso términos que aparecen menos de 3 ( $<3$ ) se eliminan de la bolsa de palabras.

Luego se realizará el proceso de normalización mediante stemming para las palabras de la bolsa de palabras (unigramas y bigramas) resultante del anterior proceso.

En este punto como se verá más adelante, en las pruebas se medirá la eficacia de aplicar ambos procesos (stopwords y stemming) en el proceso de análisis de sentimiento.

## 6. PONDERACION DE LAS CARACTERISTICAS

Las características extraídas en el paso anterior pueden ser consideradas de igual importancia u otorgarles distintos pesos en función de algún tipo de criterio. Estos pesos determinan la relevancia de cada característica dentro del texto del que pertenecen y por lo tanto influyen en el momento de clasificar los textos en los valores de verdad por parte de los algoritmos de aprendizaje. Para tal fin se hará uso de las dos ponderaciones vistas en clase para las evaluaciones como se verá más adelante.

- Frecuencia absoluta (Term Occurrences o TO): aquí cada característica tiene un peso igual al número de veces que aparece en un documento dado del corpus conformado.
- Esquema TF-IDF (Term Frequency-Inverse Document Frequency): Esta ponderación otorga una mayor importancia a aquellas características que aparecen un mayor número de veces en el corpus, pero en pocos documentos del mismo.

## 7. MODELADO DE TEMAS (TOPIC MODELING)

Sobre el corpus definitivo se aplicarán técnicas de Modelado de Temas (Topic Modeling) con el propósito de descubrir automáticamente los principales temas presentes en las noticias.

A diferencia de la clasificación supervisada realizada posteriormente para determinar si una noticia es falsa o verdadera, el modelado de temas constituye un proceso no supervisado cuyo objetivo será descubrir grupos de términos relacionados que permitan caracterizar temáticamente los documentos. Se implementarán y compararán las siguientes técnicas vistas en clase: Latent Semantic Analysis (LSA) y Latent Dirichlet Allocation (LDA).

### 7.1. LSA

Para implementar LSA, utilizar una representación apropiada de los documentos y aplicar reducción de dimensionalidad mediante SVD, de acuerdo con el procedimiento visto en clase. Para cada tema encontrado deberán presentarse las 10 palabras con mayor peso y realizar una interpretación manual del significado del tema.

### 7.2. LDA

Implementar adicionalmente Latent Dirichlet Allocation (LDA) utilizando Gensim. El modelo deberá recibir la representación Bag of Words del corpus y generar como resultado la distribución de palabras correspondiente a cada tema. Para cada tema se deberán mostrar las 10 palabras más representativas.

### 7.3. Determinación del número de temas

El número de temas  $k$  no podrá establecerse arbitrariamente. Se deberán experimentar diferentes valores de  $k$  dentro de un intervalo razonable, por ejemplo:

- $k = 2, 3, 4, \dots, 10$

y calcular para cada configuración el Score de Coherencia.

Generar una gráfica:

- Número de temas ( $k$ ) vs. Score de Coherencia

A partir de estos resultados seleccionar y justificar el número de temas utilizado finalmente.

### 8. ANÁLISIS DE TEMAS SEGÚN LA VERACIDAD DE LAS NOTICIAS

Utilizando el modelo de temas seleccionado, determinar el tema dominante de cada documento. Posteriormente comparar la distribución de los temas encontrados entre:

- Noticias Verdaderas vs. Noticias Falsas.

Luego, construir una tabla de la forma:

| Tema   | Palabras representativas | Verdaderas (%) | Falsas (%) | Interpretación |
|--------|--------------------------|----------------|------------|----------------|
| Tema 1 | ...                      |                |            |                |
| Tema 2 | ...                      |                |            |                |
| ...    | ...                      |                |            |                |

Generar un gráfico comparativo que muestre la distribución porcentual de los temas para las dos clases.

Analizar:

- ¿Existen temas con una presencia proporcionalmente diferente entre las noticias falsas y verdaderas?

### 9. ANÁLISIS INTEGRADO DEL CORPUS

A partir de los resultados obtenidos mediante POS Tagging, NER y Topic Modeling, realizar un análisis conjunto de las características lingüísticas y semánticas de las noticias. Se deberá identificar y justificar al menos tres patrones relevantes encontrados en el corpus. Estos patrones podrán estar relacionados con:

- Uso de determinadas categorías gramaticales;
- Presencia de determinados tipos de entidades;
- Entidades específicas recurrentes;

- Temas predominantes;
- Diferencias entre noticias falsas y verdaderas.

Finalmente, se deberá generar un análisis si alguno de estos patrones podría ser utilizado posteriormente como información adicional para mejorar un sistema automático de detección de noticias falsas el cual hará parte del informe a presentar.

## 10. TECNICAS DE APRENDIZAJE UTILIZADAS

Se compararán cuatro algoritmos (regresión logística, árboles de decisión, k vecinos más cercanos-KNN y máquinas de vectores de soporte- SVM) para realizar la tarea de análisis sobre si la noticia es verdadera o falsa. Para su comparación se fabricarán varios ambientes acordes a los pasos anteriormente descritos como se describe a continuación.

- Reducción y Normalización del corpus: Se probarán 4 combinaciones distintas de reducción del espacio vectorial: sin ninguna técnica, solo aplicando la eliminación de stopwords, solo mediante stemming y con ambas a la vez.
- Ponderación de las características: existirán modelos con cada una de las 2 técnicas relacionadas: Frecuencia absoluta (TO) y TF-IDF.

Para cada técnica y caso de estudio se construirá la entrada a la técnica que consistirá en la matriz de características y sus etiquetas respectivas de cada documento siendo 1 noticia verdadera, 0 noticia falsa.

Las métricas utilizadas para cada uno de los casos serán: *Accuracy*, Precisión, *Recall* y *F1-score*.

Para obtener una mayor fiabilidad en los resultados y evitar efectos no deseados de sobreajuste (*overfitting*), se probarán todos los modelos mediante un esquema de validación cruzada de k iteraciones en donde k es igual a 10. La medida de referencia será el valor  $F_1$  ponderado. Se usará para los datos de entrenamiento el 80% de los mensajes y el 20% será para Test del corpus originalmente obtenido en el punto 1.

Para mostrar los resultados, hacer uso de la siguiente tabla que detalla cada una de las configuraciones de los modelos.

| # | POND   | STOPWORDS | STEMMING | REGRESIÓN LOGÍSTICA |        |          | ARBOLES DE DECISIÓN |        |          | K VECINOS MAS CERCANOS |        |          | MAQUINA DE VECTORES DE SOPORTE |        |          |
|---|--------|-----------|----------|---------------------|--------|----------|---------------------|--------|----------|------------------------|--------|----------|--------------------------------|--------|----------|
|   |        |           |          | PRECISION           | RECALL | F1-SCORE | PRECISION           | RECALL | F1-SCORE | PRECISION              | RECALL | F1-SCORE | PRECISION                      | RECALL | F1-SCORE |
| 1 | TO     | FALSE     | FALSE    |                     |        |          |                     |        |          |                        |        |          |                                |        |          |
| 2 | TO     | TRUE      | FALSE    |                     |        |          |                     |        |          |                        |        |          |                                |        |          |
| 3 | TO     | FALSE     | TRUE     |                     |        |          |                     |        |          |                        |        |          |                                |        |          |
| 4 | TO     | TRUE      | TRUE     |                     |        |          |                     |        |          |                        |        |          |                                |        |          |
| 5 | TF-IDF | FALSE     | FALSE    |                     |        |          |                     |        |          |                        |        |          |                                |        |          |
| 6 | TF-IDF | TRUE      | FALSE    |                     |        |          |                     |        |          |                        |        |          |                                |        |          |
| 7 | TF-IDF | FALSE     | TRUE     |                     |        |          |                     |        |          |                        |        |          |                                |        |          |
| 8 | TF-IDF | TRUE      | TRUE     |                     |        |          |                     |        |          |                        |        |          |                                |        |          |

Basado en esta tabla generar las siguientes gráficas y realizar un análisis de los resultados mostrados en la figura:

- Diagrama de barras con el F1-Score máximo por algoritmo(general)
- Diagrama de barras con el F1-Score medio por ponderación y algoritmo
- Diagrama de barras con el F1-Score medio por técnica de reducción y algoritmo

Generar en su informe unas conclusiones de sus resultados.

## 11. CONCLUSIONES INTEGRALES DEL ESTUDIO

Elaborar conclusiones integrales generales del estudio, relacionando los resultados del análisis lingüístico y semántico con el desempeño de los algoritmos de clasificación y determinando qué técnicas de preprocesamiento, representación y aprendizaje automático presentan los resultados más relevantes para el problema estudiado.

## 12. ENTREGABLES

- Informe de la práctica que incluya:
  - Descripción del proceso de creación y caracterización del corpus.
  - Descripción de las técnicas de preprocesamiento, tokenización, reducción y normalización utilizadas.
  - Análisis POS Tagging, incluyendo tablas, gráficos y comparación entre noticias falsas y verdaderas.
  - Análisis de Entidades Nombradas (NER), incluyendo distribución de entidades, entidades más frecuentes, gráficos y análisis de errores.
  - Descripción de la extracción y ponderación de características mediante BoW, TO y TF-IDF.
  - Modelado de temas mediante LSA y LDA, incluyendo determinación del número de temas, palabras representativas, interpretación de los temas y comparación entre noticias falsas y verdaderas.
  - Análisis integrado del corpus a partir de los resultados de POS + NER + Topic Modeling.
  - Descripción de la configuración de las técnicas de aprendizaje supervisado utilizadas para clasificar noticias falsas y verdaderas.
  - Resultados de Accuracy, Precision, Recall y F1-score y las gráficas comparativas solicitadas junto con el análisis de resultados.
  - Conclusiones integrales.
- Código fuente desarrollado
- Corpus generado

## 8. FORMA DE ENTREGA.

Se entregará en un archivo zip con el siguiente formato: Practica1-EX.zip, donde la **X** es en número del equipo. Este archivo se subirá en la página del curso en Google Classroom y deberá contener los entregables relacionados en el numeral anterior.